

## 他的观点

氪石是通用函数近似定理的反例

## 他的证明

- 他是怎么证明通用函数近似定理是错误的
  - 使用了基于多项式基扩展的逻辑回归无效
  - 使用了GPT2进行特征提取的逻辑回归无效

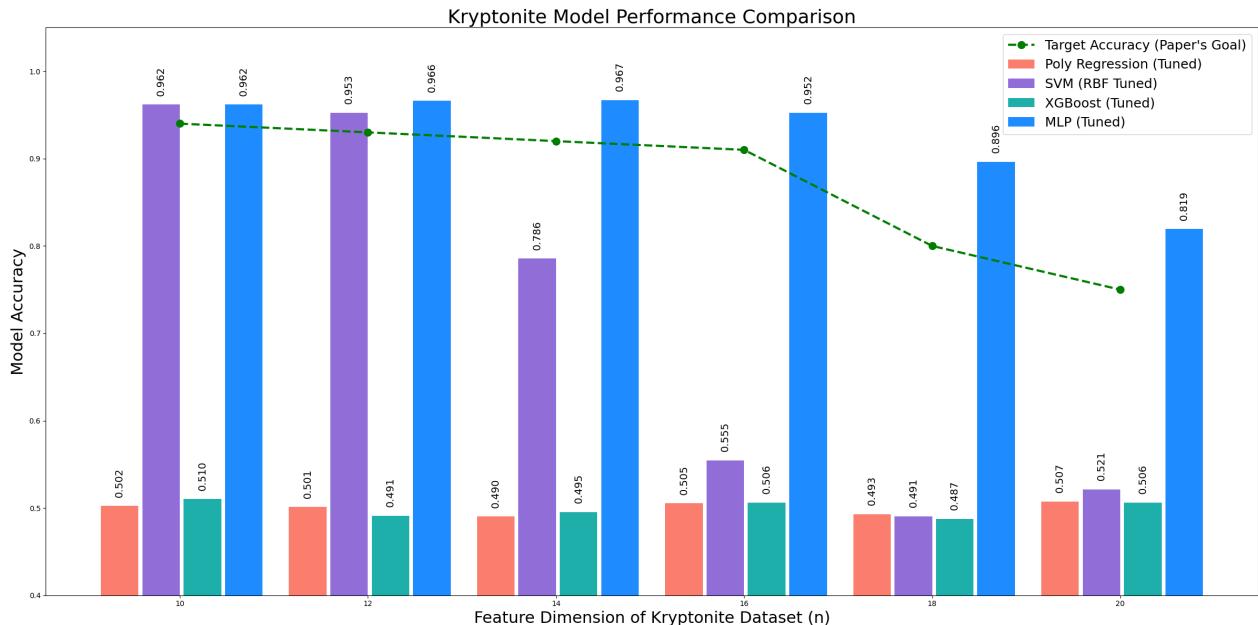
## 他的未来工作

- 不同的机器学习模型
  - 他也说了需要非线性决策平面
- 不同的学习器
  - 影响不大，在实验中体现
- 收敛性分析
  - loss曲线，在实验中体现
- 函数近似
  - 他也讲出基函数的扩展存在局限性
    - 这里可以跟SVM(RBF)进行对比，尝试扩展到无限维
- 预测不确定性
  - 噪声分析
  - 自信程度分析，在实验中体现

## 我的反驳逻辑

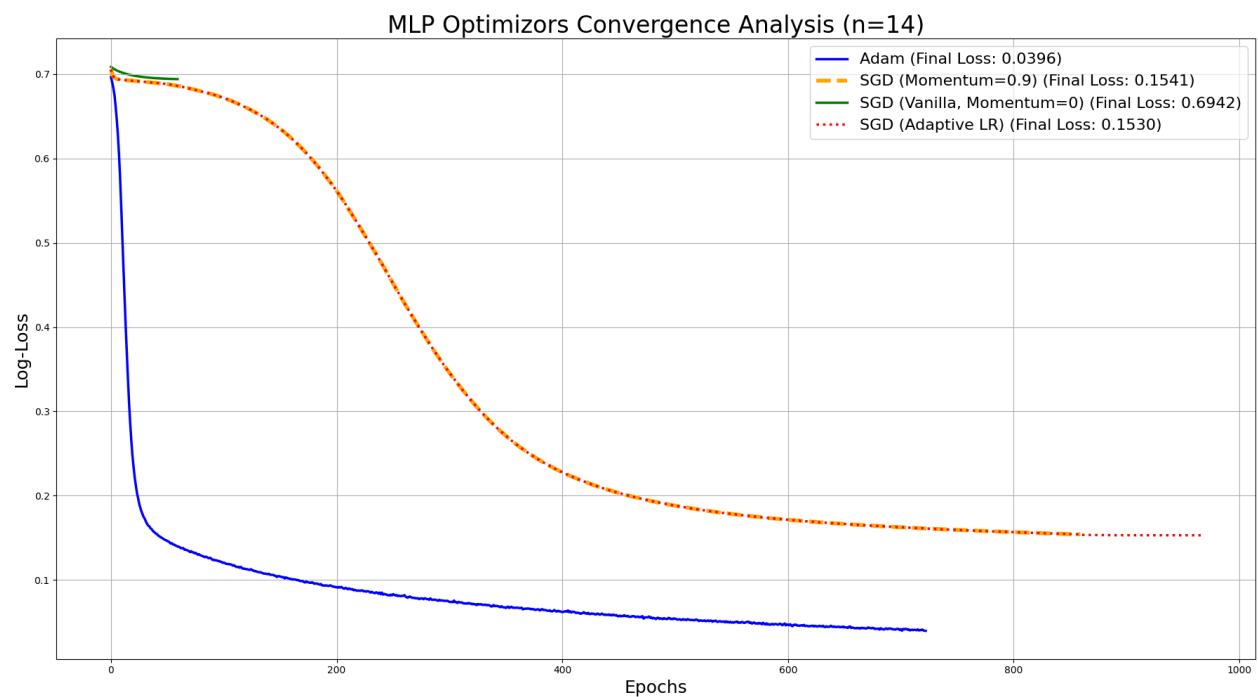
- 证明他的证明方法是存在问题的
  - 基于基扩展的对数逻辑回归
    1. 基扩展是非常局限的
    2. 多项式基扩展带来极大的维度，导致训练数据不够
    3. 采用基扩展的对数逻辑回归仍然是参数的线性模型
    4. 反映出数据集的真实边界显然不是一个简单的多项式
  - 基于GPT-2的对数逻辑回归
- 辅助证明（证明数据集的特征）
  - 采用RBF核的SVM

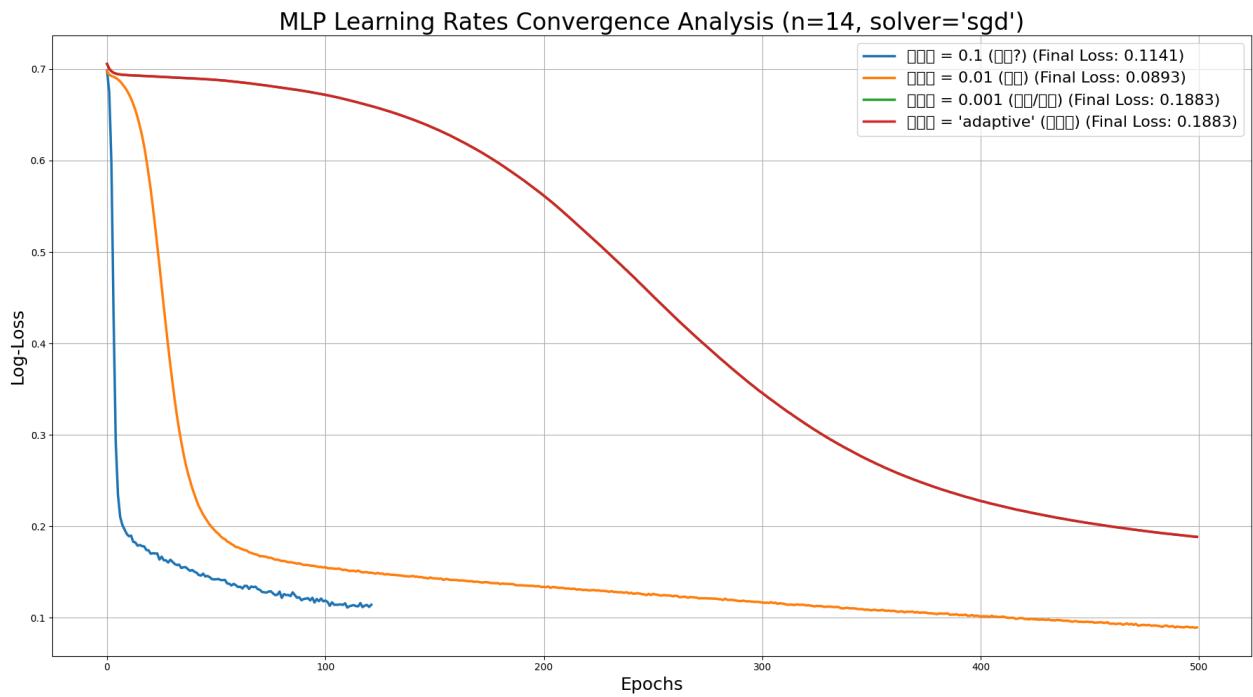
1. 可以将数据扩展到无限维，辅助证明基扩展的局限性
  2. 核函数基于欧氏距离，带来严重的维度灾难
  3. 辅助证明哪怕是扩展到无限维，基于基扩展的对数逻辑回归也有问题，对数逻辑回归需要的数据量不够
    - XGBoost
      1. 决策屏幕平行于坐标轴，导致严重的欠拟合
      2. 辅助证明基于树的方法有限，证明数据集的边界是“倾斜”的
- 有效模型
    - 单隐藏层MLP
      1. MLP不进行固定的基扩展，而是学习模型的权重进行变换，不会导致特征数量剧增
      2. MLP不计算距离，不受维度灾难影响
      3. MLP学习可旋转的决策平面，不受XGBoost的轴对齐数据限制
      4. MLP的每一个神经元经过非线性激活函数得到一个非线性的决策平面，输出为多个可学习的非线性决策平面，构建一个复杂的决策曲面（通用逼近定理）
      5. 通过实验证明MLP有效即可证明通用逼近定理有效
  - 实验设置
    - 信息介绍
      - 实验设置介绍
      - 数据集介绍
      - 参数选择方法介绍，网格搜索+K折分析
    - 性能实验
      - 多项式扩展逻辑回归-性能差
      - SVM-高维度性能差
      - XGBoost-性能差
      - MLP-性能完美



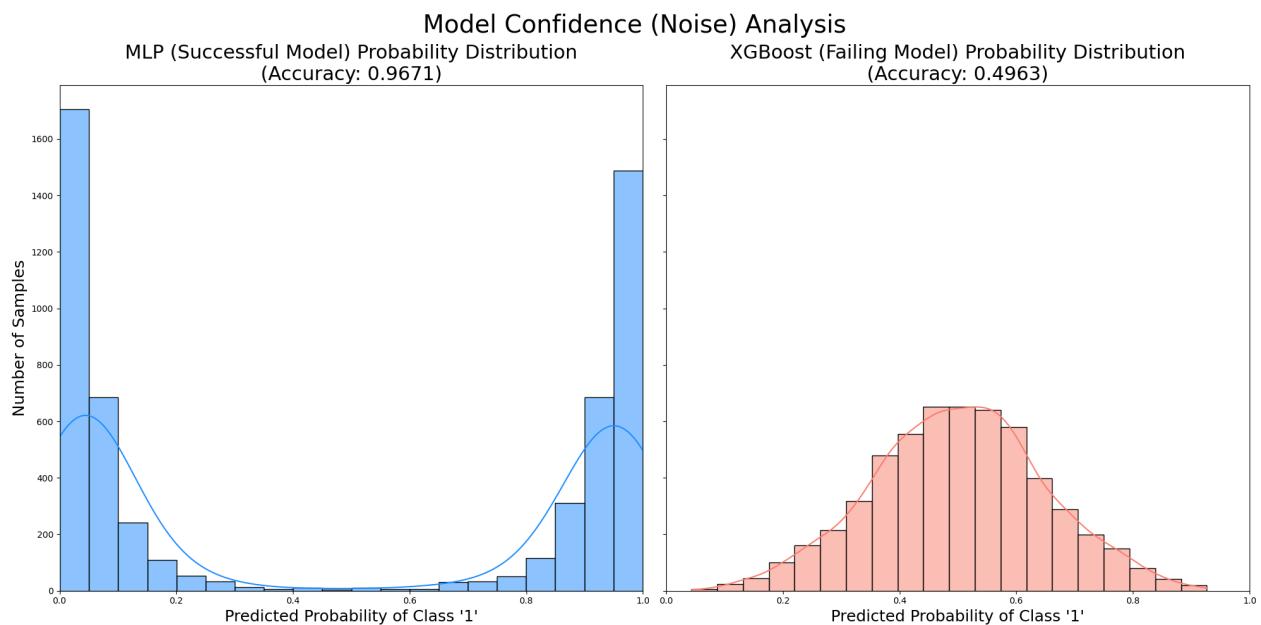
- 学习器/收敛性分析

- 学习器-只分析MLP
  - SGD
  - Adam
- 收敛性-只分析MLP
  - loss曲线





- 自信程度分析



- 计算成本分析